

Analyse und Prognose der verbleibenden Nutzungsdauer von Turbofan-Triebwerken

Projektarbeit

für

Data Analytics

(03.08.2026 – 28.08.2026)

Projektersteller/Gruppe:

Barani Shirzad, Mehrnoush

Daten:

NASA Turbofan Jet Engine Data Set


Der NASA C-MAPSS-Datensatz enthält Betriebs und Sensordaten von simulierten Turbofan-Triebwerken. Für mehrere Triebwerke werden die Betriebszustände über aufeinanderfolgende Betriebszyklen hinweg aufgezeichnet.

Der Datensatz umfasst 26 Variablen: die Triebwerks-ID (unit_number), den Betriebszyklus (time_in_cycles), drei Betriebsparameter (setting_1–setting_3) sowie 21 Sensorwerte (sensor_1–sensor_21).

Für dieses Projekt werden drei Dateien verwendet: train_FD001.txt (vollständige Lebenszyklen zum Trainieren), test_FD001.txt (Beobachtungen bis zu einem unbekannten Zeitpunkt vor dem Ausfall) sowie RUL_FD001.txt (die tatsächliche verbleibende Nutzungsdauer der Test-Triebwerke, zur Evaluation).

Die zeitliche Entwicklung der Sensorwerte ermöglicht die Untersuchung von Degradationsmustern und Veränderungen des Triebwerkszustands. Aus den Betriebszyklen kann außerdem die verbleibende Nutzungsdauer (Remaining Useful Life, RUL) bestimmt werden. Diese dient als Grundlage für die spätere Prognose mit Machine-Learning-Verfahren.

(<https://www.kaggle.com/datasets/behrad3d/nasa-cmaps>).



Projektidee, Beschreibung:

Ziel des Projekts ist die Analyse von Betriebs- und Sensordaten von Flugzeugtriebwerken auf Basis des NASA C-MAPSS-Datensatzes. Die Daten werden zunächst eingelesen, strukturell untersucht und hinsichtlich ihrer Datenqualität überprüft und bereinigt. Anschließend werden die Daten im Rahmen einer explorativen Datenanalyse (EDA) untersucht, um Verteilungen, Zusammenhänge und Veränderungen der Sensorwerte über die Betriebszyklen zu erkennen.

Ein Schwerpunkt liegt auf der Untersuchung der Sensorwerte und ihrer Entwicklung während des Betriebs der Triebwerke. Mithilfe statistischer Analysen, Korrelationsanalysen und geeigneter Visualisierungen sollen relevante Muster und Merkmale identifiziert werden. Darüber hinaus werden Unterschiede und Auffälligkeiten im Betriebsverhalten einzelner Triebwerke sowie Degradationsmuster untersucht.

Auf Basis der gewonnenen Erkenntnisse werden geeignete Data-Mining-, Machine-Learning- sowie Deep-Learning-Verfahren zur Prognose der verbleibenden Nutzungsdauer (Remaining Useful Life, RUL) angewendet und anhand geeigneter Kennzahlen bewertet und verglichen. Die wichtigsten Ergebnisse der Analyse und Modellierung werden abschließend in einem Dashboard dargestellt.

Fragen:

1. Wie verändern sich die Sensorwerte im Verlauf der Betriebszyklen, und welche Sensoren zeigen dabei erkennbare Degradationsmuster?
2. Welche Sensoren zeigen einen relevanten Zusammenhang mit der verbleibenden Nutzungsdauer (RUL)?
3. Gibt es auffällige Unterschiede im Betriebsverhalten einzelner Triebwerke (z. B. ungewöhnlich kurze/lange Lebensdauer)?
4. Wie gut lässt sich die verbleibende Nutzungsdauer anhand der verfügbaren Daten prognostizieren?

5. Wie lässt sich der Gesundheitszustand eines einzelnen Triebwerks verständlich und nachvollziehbar darstellen (z. B. im Dashboard)?

Diese Fragen werden im Verlauf der Projektschritte beantwortet.

Technischer Stack (je Projektphase):

Phase	Bibliotheken
Datenverarbeitung	pandas, numpy
EDA (Schritt 4)	matplotlib, seaborn
Data Storytelling (Schritt 5)	plotly express
Feature Engineering (Schritt 6)	pandas, numpy
Modellierung (Schritt 8)	scikit-learn (Linear Regression, Random Forest), xgboost, tensorflow/keras (LSTM)
Dashboard (Schritt 10)	plotly dash
Chatbot / NLP (Schritt 12)	sentence-transformers, ollama

Projektschritte:

1. Datenimport und Datenverständnis

Die Rohdaten (train_FD001.txt, test_FD001.txt, RUL_FD001.txt) wurden eingelesen und mit sprechenden Spaltennamen versehen (unit_number, time_in_cycles, setting_1–setting_3, sensor_1–sensor_21). Die grundlegende Struktur wurde für alle drei Dateien geprüft: Anzahl der Zeilen und Spalten, Datentypen je Spalte sowie ein erster Blick auf die Anzahl der enthaltenen Triebwerke und deren Zyklenanzahl. Der Fokus der weiteren Analyse und Modellierung liegt zunächst auf train_FD001.txt, da dieser Datensatz vollständige Lebenszyklen enthält; test_FD001.txt und RUL_FD001.txt werden entsprechend vorbereitet und für die spätere finale Modellevaluation zurückgehalten. Diese Grundlage war notwendig, um die nachfolgende Qualitätsprüfung gezielt durchführen zu können.

2. Datenqualität

Aufbauend auf dem Datenverständnis aus Schritt 1 erfolgte eine strukturelle Prüfung der Trainingsdaten: Kontrolle auf fehlende Werte, Duplikate, inkonsistente Zyklusnummerierungen sowie eine erste Betrachtung von Ausreißern (u. a. mittels IQR-Analyse) und der Wertespanssen einzelner Sensoren. Zusätzlich wurde die Lebensdauer je Triebwerk berechnet, um einen ersten Überblick über deren Streuung zu erhalten. Diese Prüfung war entscheidend, um bereits vor der eigentlichen Analyse zu erkennen, dass der Datensatz strukturell sauber ist (keine fehlenden Werte, keine Duplikate) und die Hauptherausforderung stattdessen in der unterschiedlichen Informationsdichte einzelner Sensoren liegt.

3. Datenaufbereitung

Auf Basis der Datenqualitätsprüfung wurden konstante bzw. nahezu konstante Spalten identifiziert und entfernt, dazu zählen sensor_1, sensor_10, sensor_18 und sensor_19 sowie der

Betriebsparameter `setting_3`, die im FD001-Subset keine bzw. vernachlässigbare Varianz aufweisen und daher keinen Informationsgehalt liefern. Dies ist typisch für FD001, da dieses Subset nur eine einzige Betriebsbedingung und einen einzigen Fehlermodus umfasst, wodurch Merkmale, die primär auf wechselnde Betriebsbedingungen reagieren, hier flach bleiben. Die Zielvariable RUL wurde je Zeile berechnet als Differenz zwischen der maximalen Zyklenzahl des jeweiligen Triebwerks und dem aktuellen Betriebszyklus. Ergebnis dieses Schritts ist der bereinigte Trainingsdatensatz `train_clean` mit 21 verbleibenden Spalten (inkl. RUL), der als Grundlage für alle weiteren Schritte (EDA, Feature Engineering, Modellierung) dient; der entsprechend bereinigte Testdatensatz `test_clean` wird separat für die finale Modellevaluation vorgehalten.

4. Explorative Datenanalyse (EDA)

Der bereinigte Datensatz wurde umfassend explorativ untersucht, gegliedert in vier Teilbereiche:

- **Univariate Analyse** – Verteilungen und Varianz aller verbliebenen Sensoren (Histogramme, Boxplots, Kennzahlen); zeigte zudem, dass die verbliebenen Settings (`setting_1`, `setting_2`) sich auf wenige diskrete Werte konzentrieren, was die Annahme einer einzigen Betriebsbedingung in FD001 bestätigt
- **Korrelationsanalyse** – Sensor-Sensor-Korrelationen (Heatmap) sowie Sensor-RUL-Korrelationen zur Identifikation relevanter Merkmale
- **Degradationsmuster** – Entwicklung der Sensorwerte über die Betriebszyklen hinweg; Sensoren mit den deutlichsten, konsistentesten Trends sind `sensor_11`, `sensor_4`, `sensor_12`, `sensor_7`, `sensor_21` und `sensor_20`. Charakteristisch für nahezu alle degradationsrelevanten Sensoren ist ein zweiphasiger Verlauf: eine lange, nahezu stabile Phase, gefolgt von einer beschleunigten Veränderung in den letzten Zyklen vor dem Ausfall
- **Vergleich einzelner Triebwerke** – Verteilung der Triebwerkslebensdauer ($\bar{x}$ 206,3 Zyklen, Std. 46,3, Spanne 128–362 Zyklen), Identifikation der Ausreißer-Triebwerke (Unit 39 kürzeste, Unit 69 längste Lebensdauer)

Dieser Schritt liefert erste Antworten auf die Projektfragen 1, 2 und 3 und bildet die inhaltliche Grundlage für alle nachfolgenden Entscheidungen im Feature Engineering.

5. Data Storytelling / Visualisierung

Aufbauend auf Schritt 4 wurden die wichtigsten Ergebnisse in eine kompakte, präsentationsreife Auswahl an Visualisierungen überführt (primär `plotly express`, ergänzend `seaborn/matplotlib`): Degradationstrend der stärksten RUL-korrelierten Sensoren, Ranking der Sensor-RUL-Korrelationen (14 Sensoren mit $|r| > 0,3$, angeführt von `sensor_11` mit $r = -0,696$, `sensor_4` mit $r = -0,679$ und `sensor_12` mit $r = +0,672$), Verteilung der Triebwerkslebensdauer mit hervorgehobenen Extremwerten, direkter Sensorvergleich zwischen kürzestem, typischem (Unit 26, 199 Zyklen) und längstem Triebwerk, reduzierte Korrelations-Heatmap sowie die RUL-Gesamtverteilung als Vorbereitung für das anstehende Clipping. Die bewusste Trennung von explorativer Analyse (Schritt 4, viele Plots, technischer Fokus) und Storytelling (Schritt 5, wenige kuratierte Plots, verständlichkeitsorientiert) stellt sicher, dass die spätere Berichterstellung und das Dashboard auf bereits vorselektierten, aussagekräftigen Visualisierungen aufbauen können, statt auf der vollständigen EDA-Rohausgabe.

6. Feature Engineering

Aus den 14 relevanten Sensoren wurde das finale Merkmalsset erstellt: RUL-Clipping bei 125 Zyklen (RUL_clipped), ein in der C-MAPSS-Literatur etablierter Schwellenwert, um den informationsarmen Bereich hoher RUL-Werte zu begrenzen, in dem Sensorwerte noch keine erkennbare Degradation zeigen und somit auch für ein Modell nicht vorhersagbar sind; zeitbezogene Merkmale je Triebwerk (Rolling Mean und Rolling Std über ein 5-Zyklen-Fenster zur Glättung von Sensorrauschen, sowie Differenzmerkmale zum Vorzyklus zur Erfassung der unmittelbaren Änderungsrate). Die dadurch am jeweils ersten Zyklus eines Triebwerks entstehenden NaN-Werte (kein vorheriger Wert bzw. kein vollständiges Fenster) wurden mit 0 aufgefüllt. Die Skalierung wurde bewusst noch nicht durchgeführt, sondern erst in den nächsten Schritt verschoben, um Data Leakage zwischen Trainings und Validationsdaten von vornherein auszuschließen.

7. Train/Test Split (nach unit_number)

Die Trainingsdaten wurden zusätzlich in einen Trainings- und einen Validation-Anteil aufgeteilt (80 % Training / 20 % Validation, nach unit_number, random_state=42), statt eines zeilenbasierten Splits, um zu verhindern, dass Zyklen desselben Triebwerks gleichzeitig in Training und Validation landen und dadurch die zeitliche Korrelation innerhalb eines Triebwerks die Modellbewertung künstlich verbessert. Eine explizite Prüfung stellte sicher, dass keine Überschneidung der Triebwerks-IDs zwischen beiden Mengen vorliegt. Dieser interne Validation-Split ermöglicht eine faire, wiederholbare Bewertung und einen Modellvergleich während der Entwicklung, ohne den offiziellen Testdatensatz vorzeitig zu verwenden. Da der Testdatensatz genau einmal – erst nach Abschluss aller Modellierungsentscheidungen – zur unverfälschten Generalisierungsprüfung herangezogen werden sollte, wird er bewusst nicht für Modellvergleich, Hyperparameter-Wahl oder sonstige Zwischenentscheidungen genutzt.

Die Standardisierung mittels StandardScaler wurde ausschließlich auf den Trainingsdaten gefittet und anschließend per transform auf die Validation angewendet, wodurch keine Information aus der Validation in die Skalierungsparameter (Mittelwert, Standardabweichung) einfließt. Der offizielle Testdatensatz (test_FD001.txt, RUL_FD001.txt) wurde bereits eingelesen und bereinigt (test_clean), blieb für die im Rahmen dieses Projekts berichteten Ergebnisse jedoch vollständig unangetastet und ist für eine spätere, abschließende Evaluation vorgesehen (siehe Limitationen/Ausblick).

8. Data Mining / Machine Learning

Fünf Modelle wurden trainiert und verglichen: Mean Baseline (als unteres Vergleichsniveau), Linear Regression, Random Forest, XGBoost sowie ein LSTM auf zeitlichen Sequenzen. Für das LSTM wurden die Daten in ein dreidimensionales Format (Anzahl Sequenzen $\times$ Sequenzlänge $\times$ Anzahl Merkmale) überführt, mit einer festen Sequenzlänge von 30 Zyklen, gebildet ausschließlich innerhalb einzelner Triebwerke, um keine zwei unabhängigen Degradationsverläufe zu vermischen; kürzere Triebwerke wurden am Anfang gepaddet. Für alle Modelle wurden einheitlich RMSE, MAE, R^2 sowie ein eigens implementierter NASA-Score berechnet, der auf der asymmetrischen NASA-Kostenfunktion basiert und verspätete Vorhersagen (zu spät gewarnt) deutlich stärker bestraft als zu frühe, konservative Vorhersagen – ein für Predictive-Maintenance-Anwendungen praxisrelevanteres Kriterium als reine RMSE-Werte. Die Feature-Importance-Analyse von Random Forest und XGBoost bestätigte sensor_4 und sensor_11 (insbesondere deren Rolling-Mean-Merkmale) als wichtigste Prädiktoren – im

Einklang mit den Korrelationsergebnissen aus Schritt 5, was die Konsistenz zwischen statistischer Voranalyse und tatsächlichem Modellverhalten unterstreicht.

9. Modellbewertung

Vertiefende Bewertung der fünf Modelle anhand eines Summenrangs über alle vier Kennzahlen: Das LSTM erzielt insgesamt die beste Leistung (RMSE 14,88, MAE 10,27, R^2 0,873, NASA-Score 4,68), gefolgt von XGBoost und Random Forest (RMSE je $\approx$ 16,56, R^2 0,842). Eine zusätzliche Fehleranalyse nach RUL-Bereichen (0–25, 25–50, 50–75, 75–100, 100–125 Zyklen) zeigte jedoch ein differenzierteres Bild: Im sicherheitskritischen Bereich kurz vor dem Ausfall (RUL 0–25) übertreffen XGBoost (RMSE 6,11) und Random Forest (RMSE 6,24) das LSTM (RMSE 8,51) deutlich. Ergänzend wurden die Modelle nach qualitativen, nicht-numerischen Kriterien verglichen – Interpretierbarkeit, Trainingsaufwand und Nutzung der zeitlichen Struktur – wodurch deutlich wird, dass die Modellwahl in der Praxis nicht allein von der Gesamtgenauigkeit abhängen sollte: Für ein sicherheitskritisches Frühwarnsystem sind die Baumverfahren trotz insgesamt niedrigerer Gesamtgenauigkeit im entscheidenden Bereich vorzuziehen und zugleich deutlich transparenter in ihren Vorhersagen.

10. Dashboard

Ein interaktives plotly dash-Dashboard mit vier Tabs führt die Ergebnisse zusammen: (1) Übersicht mit Kennzahlen zu Triebwerksanzahl, Beobachtungsanzahl, durchschnittlicher/kürzester/längster Lebensdauer sowie Verteilungsplots zu Lebensdauer und RUL, (2) Triebwerkszustand mit wählbarer Unit, automatischer Statusklassifikation (Normal/Attention/Warning/Critical anhand der aktuellen RUL) und RUL-Verlauf über die Betriebszyklen, (3) Sensoranalyse mit frei wählbarem Sensor- und Triebwerksverlauf sowie einer Scatter-Darstellung des Sensor-RUL-Zusammenhangs inklusive Trendlinie, (4) Modellperformance mit Vergleich aller fünf Modelle nach RMSE, R^2 und NASA-Score. Durch die Kombination aus quantitativen Kennzahlen, Zeitreihen- und Zusammenhangsdarstellungen macht das Dashboard sowohl den technischen Modellvergleich als auch den individuellen Triebwerkszustand für technisch fachfremde Nutzer nachvollziehbar zugänglich und schließt damit den Bogen vom rohen Sensordatensatz bis zur handlungsrelevanten Darstellung.

11. Lokaler RAG-Chatbot (NLP-Komponente)

Als ergänzende NLP-Komponente wurde ein lokaler, retrieval-augmentierter Chatbot entwickelt, der Fragen zum Projekt in natürlicher Sprache beantwortet. Die Wissensbasis wird automatisch aus den bereits vorliegenden Projektergebnissen generiert, u. a. aus der Sensor-RUL-Korrelation (Schritt 5), der Triebwerks-Lebensdauer (Schritt 5), dem Modellvergleich inklusive kritischem RUL-Bereich (Schritt 9), der Feature Importance (Schritt 8) sowie den individuellen Triebwerksstatus-Daten (Schritt 10), und nicht manuell verfasst.

Technisch kombiniert der Chatbot zwei Komponenten: Für das **Retrieval** werden alle Wissensbausteine sowie die Nutzerfrage mittels eines lokalen Embedding-Modells (all-MiniLM-L6-v2, sentence-transformers) in Vektoren überführt; über Cosine Similarity werden die drei relevantesten Textbausteine zur gestellten Frage ermittelt. Für die **Generierung** wird ein lokal über Ollama betriebenes Qwen-Sprachmodell verwendet, das ausschließlich auf Basis der abgerufenen Textbausteine antwortet und explizit angewiesen ist, bei fehlender Information dies ehrlich zu benennen statt zu spekulieren. Der Chatbot läuft vollständig lokal, ohne externe

API oder Internetverbindung, und lässt sich interaktiv über die Konsole befragen (z. B. „Welches Modell hat die beste Performance?“, „Wie ist der Zustand von Unit 39?“).

Diese Komponente macht die Projektergebnisse zusätzlich über eine natürlichsprachliche Schnittstelle zugänglich, ergänzend zum visuellen Dashboard aus Schritt 10.

12. Beantwortung der Fragen / Fazit

12.1. Beantwortung der Projektfragen

Frage 1: Wie verändern sich die Sensorwerte im Verlauf der Betriebszyklen, und welche Sensoren zeigen dabei erkennbare Degradationsmuster?

Die Degradationsanalyse in den Schritten 4 und 5 zeigt, dass mehrere Sensoren über den Lebenszyklus der Triebwerke erkennbare, überwiegend monotone Trends aufweisen. Bei vielen dieser Sensoren bleiben die Werte zunächst über einen längeren Zeitraum relativ stabil und verändern sich insbesondere in den letzten Betriebszyklen vor dem Ausfall deutlicher. Dieses Verhalten kann als Hinweis auf eine zunehmende Degradation des Triebwerks interpretiert werden.

Besonders auffällige und konsistente Zusammenhänge zeigen **sensor_11, sensor_4, sensor_12, sensor_7, sensor_21 und sensor_20**. Diese Sensoren weisen gleichzeitig eine hohe absolute Korrelation mit der RUL auf.

Andere Merkmale, darunter sensor_1, sensor_10, sensor_18 und sensor_19 sowie der Betriebsparameter setting_3, zeigen dagegen keine bzw. nur eine sehr geringe Varianz. Sie wurden in Schritt 3 als konstant bzw. nahezu konstant identifiziert und daher entfernt; sie liefern folglich keine Information für die weitere Analyse.

Ergebnis: Die Sensoren zeigen ein unterschiedliches Verhalten über den Lebenszyklus. Insbesondere sensor_11, sensor_4, sensor_12, sensor_7, sensor_21 und sensor_20 liefern deutliche Hinweise auf Degradationsprozesse.

Frage 2: Welche Sensoren zeigen einen relevanten Zusammenhang mit der verbleibenden Nutzungsdauer (RUL)?

Die Korrelationsanalyse zeigt, dass **14 der untersuchten Sensoren** einen relevanten Zusammenhang mit der RUL aufweisen ($|r| > 0,3$).

Die stärksten Zusammenhänge zeigen:

- **sensor_11:** $r = -0,696$
- **sensor_4:** $r = -0,679$
- **sensor_12:** $r = +0,672$

Weitere relevante Sensoren sind **sensor_7, sensor_21, sensor_15, sensor_20, sensor_2 und sensor_17**, die ebenfalls vergleichsweise hohe absolute Korrelationswerte aufweisen.

Diese Ergebnisse stimmen mit der späteren Modellierung überein. Insbesondere die Feature-Importance-Analyse der Random-Forest- und XGBoost-Modelle zeigt, dass Merkmale auf Basis von **sensor_4** und **sensor_11**, insbesondere deren Rolling-Mean-Merkmale, einen wichtigen Beitrag zur RUL-Prognose leisten.

Ergebnis: sensor_11, sensor_4 und sensor_12 zeigen den stärksten statistischen Zusammenhang mit der RUL. Die Korrelationsanalyse liefert damit eine Grundlage für die Auswahl relevanter Merkmale für die Modellierung.

Frage 3: Gibt es auffällige Unterschiede im Betriebsverhalten einzelner Triebwerke, z. B. ungewöhnlich kurze oder lange Lebensdauer?

Ja. Die Analyse der 100 Trainings-Triebwerke zeigt deutliche Unterschiede in der Lebensdauer.

Die durchschnittliche Lebensdauer beträgt **206,3 Betriebszyklen** bei einer Standardabweichung von **46,3 Zyklen**. Die kürzeste Lebensdauer beträgt **128 Zyklen (Unit 39)**, während **Unit 69 mit 362 Zyklen** die längste Lebensdauer aufweist. Damit liegt zwischen dem kürzesten und längsten Triebwerk ein deutlicher Unterschied vor.

Der Vergleich eines Triebwerks mit kurzer Lebensdauer, eines typischen Triebwerks (**Unit 26, 199 Zyklen**) und des Triebwerks mit der längsten Lebensdauer zeigt unterschiedliche Verläufe der Sensorwerte. Die Form und Steilheit der Degradationskurven unterscheiden sich zwischen den Triebwerken. Gleichzeitig ist bei den betrachteten Triebwerken grundsätzlich eine längere stabile Phase mit anschließender stärkerer Veränderung vor dem Ausfall erkennbar.

Ergebnis: Die Triebwerke weisen deutlich unterschiedliche Lebensdauern und individuelle Degradationsverläufe auf.

Frage 4: Wie gut lässt sich die verbleibende Nutzungsdauer anhand der verfügbaren Daten prognostizieren?

Die Ergebnisse der Modellierung zeigen, dass sich die verbleibende Nutzungsdauer auf Basis der verfügbaren Betriebs- und Sensordaten gut prognostizieren lässt. Alle trainierten Modelle übertreffen die Mean-Baseline mit einem RMSE von **41,72** deutlich.

Das **LSTM-Modell** erzielt insgesamt die beste Leistung mit:

- **RMSE:** 14,88
- **MAE:** 10,27
- **R²:** 0,873
- **NASA Score:** 4,68

Damit erreicht das LSTM über die betrachteten Gesamtkennzahlen die beste Modellleistung. Danach folgen **XGBoost** und **Random Forest**, die jeweils einen RMSE von etwa **16,56** und ein R² von etwa **0,842** erreichen.

Eine differenzierte Betrachtung des kritischen Bereichs mit einer RUL von **0–25 Zyklen** zeigt jedoch ein anderes Bild. In diesem Bereich erreichen **XGBoost (RMSE 6,11)** und **Random Forest (RMSE 6,24)** bessere Ergebnisse als das LSTM-Modell (RMSE 8,51).

Ergebnis: Das LSTM erzielt insgesamt die beste Prognoseleistung. Für die besonders kritische Phase unmittelbar vor dem Ausfall zeigen jedoch XGBoost und Random Forest Vorteile.

Frage 5: Wie lässt sich der Gesundheitszustand eines einzelnen Triebwerks verständlich und nachvollziehbar darstellen?

Der entwickelte Dashboard-Teil ermöglicht die interaktive Betrachtung des Zustands eines ausgewählten Triebwerks. Die Darstellung basiert auf drei zentralen Elementen:

1. **Statusklassifikation:** Einteilung in *Normal*, *Attention*, *Warning* oder *Critical* abhängig von der prognostizierten RUL.
2. **RUL-Verlauf:** Darstellung der Entwicklung der verbleibenden Nutzungsdauer über die Betriebszyklen.
3. **Sensorverlauf:** Interaktive Auswahl und Darstellung einzelner Sensorwerte über den Lebenszyklus.

Durch die Kombination dieser Informationen kann der Zustand eines Triebwerks sowohl quantitativ als auch visuell nachvollzogen werden. Das Dashboard verbindet damit die Ergebnisse der Datenanalyse und der Machine-Learning-Modelle mit einer verständlichen Darstellung für die praktische Anwendung.

Ergebnis: Das Dashboard ermöglicht eine übersichtliche und nachvollziehbare Beurteilung des prognostizierten Zustands einzelner Triebwerke.

12.2. Fazit

Das Projekt untersucht den NASA C-MAPSS FD001-Datensatz mit dem Ziel, Betriebs- und Sensordaten von Turbofan-Triebwerken zu analysieren und die verbleibende Nutzungsdauer vorherzusagen.

Ausgehend vom Datenimport wurden die Daten zunächst strukturell untersucht und hinsichtlich ihrer Datenqualität überprüft. Dabei wurden unter anderem fehlende Werte, Duplikate, inkonsistente Zyklusnummerierungen, Varianzen und mögliche Ausreißer betrachtet. Anschließend wurden die Daten für die weitere Analyse aufbereitet.

Die explorative Datenanalyse zeigte deutliche Unterschiede zwischen den Sensoren. Während einige Sensoren nur geringe bzw. keine relevanten Veränderungen aufweisen, zeigen andere Sensoren deutliche zeitliche Degradationsmuster und einen starken Zusammenhang mit der verbleibenden Nutzungsdauer. Insbesondere **sensor_11**, **sensor_4** und **sensor_12** erwiesen sich als besonders informative Sensoren.

Die Analyse der einzelnen Triebwerke zeigte außerdem, dass sich sowohl die Lebensdauer als auch die Degradationsverläufe zwischen den Triebwerken deutlich unterscheiden. Dies verdeutlicht die Herausforderung einer zuverlässigen RUL-Prognose und die Bedeutung individueller Betriebsdaten.

Im Rahmen des Feature Engineerings wurden zusätzliche zeitbezogene Merkmale erzeugt, darunter **Rolling Means, Rolling Standard Deviations und Differenzen**. Anschließend wurden verschiedene Modellierungsverfahren miteinander verglichen. Neben einer einfachen Mean-Baseline und Linear Regression kamen **Random Forest, XGBoost und LSTM** zum Einsatz.

Die Ergebnisse zeigen, dass insbesondere Machine-Learning- und Deep-Learning-Verfahren eine deutliche Verbesserung gegenüber der Baseline ermöglichen. Das **LSTM-Modell erzielt mit einem RMSE von 14,88, einem MAE von 10,27, einem R^2 von 0,873 und einem NASA Score von 4,68 die beste Gesamtleistung**. Gleichzeitig zeigt die Analyse des kritischen Bereichs, dass **XGBoost und Random Forest bei einer RUL von 0–25 Zyklen bessere Ergebnisse als das LSTM-Modell** erreichen.

Die abschließende Dashboard-Anwendung führt die wichtigsten Ergebnisse zusammen. Sie ermöglicht die Auswahl einzelner Triebwerke und die Visualisierung ihrer RUL-Entwicklung, ihres prognostizierten Zustands sowie ausgewählter Sensorverläufe. Dadurch werden die analytischen und modellbasierten Ergebnisse verständlich und interaktiv dargestellt.

Insgesamt zeigt das Projekt den vollständigen Data-Analytics-Prozess von der Datenaufbereitung und explorativen Analyse über Feature Engineering und Machine Learning bis hin zur interaktiven Visualisierung. Die Ergebnisse zeigen, dass Sensordaten wertvolle Informationen über den Zustand und die verbleibende Nutzungsdauer von Triebwerken enthalten und somit eine geeignete Grundlage für Predictive-Maintenance-Anwendungen bilden.

Ergänzend wurde ein lokaler RAG-Chatbot entwickelt, der die Projektergebnisse zusätzlich über eine natürlichsprachliche Schnittstelle zugänglich macht.

Limitationen/ Ausblick

Limitationen

- Es wurde ein einzelner Train/Validation-Split (80/20 nach unit_number) verwendet; eine k-fold-Validierung nach Triebwerken könnte die Robustheit der Modellrangfolge zusätzlich absichern.
- Die LSTM-Sequenzen basieren auf überlappenden Fenstern ($n = 3490$) und sind damit nicht direkt mit der Zeilenanzahl der klassischen Modelle ($n = 4070$) vergleichbar; die berechneten Fehlermetriken selbst sind jedoch gleichwertig interpretierbar.
- Die Analyse beschränkt sich auf das FD001-Subset (eine Betriebsbedingung, ein Fehlermodus); eine Übertragung auf die komplexeren Subsets (FD002–FD004) mit mehreren Betriebsbedingungen wurde nicht untersucht.
- Die endgültige Bewertung auf dem offiziellen C-MAPSS-Testdatensatz (test_FD001.txt + RUL_FD001.txt) steht noch aus; die in diesem Projekt berichteten Kennzahlen beziehen sich auf den intern abgetrennten Validation-Split der Trainingsdaten.

Ausblick

Mögliche nächste Schritte wären die Evaluation auf dem offiziellen Testdatensatz, eine systematischere Hyperparameter-Optimierung (insbesondere für XGBoost und LSTM), sowie

die Erweiterung des Dashboards um eine automatisierte Wartungsempfehlung basierend auf dem vorhergesagten Gesundheitsstatus.